

SGLang 的 RadixAttention / RadixCache 解决什么问题？

RadixAttention 实现了在多次生成调用之间自动复用 KVcache。解决了多次询问间KVcache无法复用，避免了不必要的计算和内存浪费。减少了子问题的重复解决。

它可以实现跨请求的全局优化，避免了频繁的缓存置换。

SGLang 中 page-sized KV cache 与 prefix reuse 分别对应 pipeline 中的哪一部分？

page-sized KV cache 对应 pipeline 里面的内存管理器，将KVcache分成小块，储存在不同地方，处理好之后只保留那些含有关键信息的小块，把其他的分配出去。

prefix reuse对应pipeline中的请求处理阶段，如果发现请求的前缀已经出现在树中，则直接复用，不再另外计算。

vLLM 的 PagedAttention 解决什么问题？ 它和 SGLang 的RadixAttention / paged KV 机制有什么联系与差异

vLLM的PagedAttention借鉴操作系统虚拟内存机制，将KVCache分块存储，解决显存碎片化和内存分配效率低问题，关注底层物理分配问题。

SGLang的RadixAttention在pagedattention的基础上引入前缀树索引，解决跨请求的前缀重复计算问题，关注上层逻辑复用。