

SGLang: Efficient Execution of Structured Language Model Programs

研究背景：调用大语言模型对文本进行分析

研究目的：解决由于输入文本长度、内容的不确定导致的缓存的浪费和文本前缀、相同KV的重复处理

提出的方案：page-size KV cache 和 Radix attention

对方案的验证和评估：

将 SGLang 与各自具有特定语言和默认运行时的各种高级编程系统，以及提供标准 OpenAI 风格 Completion API 的低级推理引擎进行了比较，考察两项性能指标：吞吐量和延迟。得出结论，SGLang 可以很好地用于大模型并且为多模态提供原生支持。

我关注的点：

论文里面提到的通过缓存和查询缓存来避免重复处理问题的方法使我想到了记忆化搜索和动态规划，对前缀的缓存方式让我想到了字符串的前缀树，其关于分散储存的KVcache管理让我想到了链表等离散化储存的数据结构。后续的创新点或许可以在这方面产生。

Efficient Memory Management for Large LanguageModel Serving with PagedAttention

研究背景：单次询问消耗巨大，由于低效的内存管理方式导致内存受限

研究目的：研究一种更高效的内存管理机制

提出的方案：PagedAttention，把 KVcache切分成固定大小、无需连续存放的块，以块为单位按需分配

对方案的验证和评估：

用两类模型、两种数据集、不同规模的 GPU 集群来测试。模型为 OPT 系列和 LLaMA-13B；数据集为 ShareGPT和 Alpaca。核心指标是吞吐量和延迟。结果显示优化不损失模型精度。

我关注的点：

和上一个相比，少了前缀的优化，可能会多耗费一点空间在重复的但是重要的KV上面。